

Pronalazak mutacija pomoću treće generacije sekvenciranja

Monika Hušnjak, Marko Kosmač

2. lipnja 2026.

Sažetak

U radu je opisana implementacija postupka za pronalazak mutacija pomoću podataka treće generacije sekvenciranja. Korišteni su skupovi podataka za genome *lambda* i *Escherichia coli*, uz simulirana očitavanja koja sadrže poznate supstitucije, umetanja i brisanja. Očitavanja su mapirana na referentni genom alatom *Minimap2*, a dobiveni zapisi obrađeni su alatima *Samtools* i vlastitim programima u jeziku C++. Razvijeni algoritam detektira varijante iz poravnanja i filtrira ih prema pokrivenosti i potpori očitavanja. Dobiveni rezultati uspoređuju se s poznatim skupom točnih varijanti te s dodatnim rješenjem dobivenim parsiranjem *mpileup* zapisa.

1 Uvod

Sekvenciranje DNA jedna je od najvažnijih metoda moderne bioinformatike jer omogućuje određivanje redoslijeda nukleotidnih baza u genomu te analizu genetskih promjena. Razvojem tehnologija sekvenciranja pojavile su se metode treće generacije koje omogućuju dobivanje vrlo dugih očitavanja DNA. Duga očitavanja olakšavaju analizu kompleksnih i repetitivnih dijelova genoma, ali istovremeno imaju veću stopu pogreške u odnosu na tehnologije druge generacije.

Za obradu podataka dobivenih sekvenciranjem treće generacije koriste se specijalizirani algoritmi i alati za poravnanje sekvenci. Jedan od najčešće korištenih alata je *minimap2*, koji omogućuje brzo i učinkovito mapiranje dugih očitavanja na referentni genom. Nakon mapiranja moguće je analizirati dobivena poravnanja i pronaći razlike između referentnog i mutiranog genoma.

Cilj ovog projekta je identificirati mutacije u odnosu na referentni genom korištenjem očitavanja dobivenih sekvenciranjem treće generacije. Proma-

trane mutacije uključuju supstitucije, umetanje i brisanje baza. Ulazni podaci zadani su u FASTA formatu, dok se rezultati analize zapisuju u CSV datoteku koja sadrži tip mutacije, njezinu poziciju i baze koje se pojavljuju u mutaciji.

Implementacija se uspoređuje s rezultatima *SAMtools-a*, standardnog skupa alata za obradu i analizu podataka sekvenciranja zapisanih u SAM/BAM formatima. *SAMtools* omogućuje sortiranje, indeksiranje i pregled poravnanja te generiranje podataka potrebnih za detekciju varijanti.

2 Opis problema

Problem koji se rješava u ovom projektu je detekcija razlika između referentnog genoma i drugog genoma dobivenog sekvenciranjem. Referentni genom predstavlja poznati slijed nukleotida, dok se drugi genom ne promatra izravno, nego kroz skup sekvenciranih očitavanja. Ta očitavanja predstavljaju kraće dijelove genoma i potrebno ih je najprije poravnati na referentni genom.

Nakon poravnanja očitavanja moguće je analizirati na kojim se pozicijama očitane baze razlikuju od referentnih baza. Takve razlike mogu nastati zbog mutacija ili pogrešaka sekvenciranja, pa je cilj algoritma izdvojiti one promjene koje imaju dovoljno potpore u očitanjima. U ovom radu promatraju se tri osnovne vrste varijanti: supstitucije, umetanja i brisanja.

Za rješavanje problema korištena su dva skupa podataka: kraći *lambda* genom i veći genom bakterije *E. coli*. Na temelju očitavanja za svaki skup podataka izgrađen je postupak koji poravnava očitavanja na referencu, obrađuje dobivene zapise o poravnanju te detektira varijante koje predstavljaju potencijalne razlike između referentnog i sekvenciranog genoma.

3 Skup podataka

Za testiranje implementacije korišteni su skupovi podataka za *Escherichia coli* i *lambda*. Referentni genomi pohranjeni su u FASTA formatu koji se sastoji od zaglavlja sekvence i niza nukleotida zapisanih bazama A, C, G i T. Genom *E. coli* veličine je približno 4,6 milijuna baznih parova, dok genom *lambda* sadrži oko 48,5 tisuća baznih parova.

Uz referentne genome korištena su simulirana očitavanja također zapisana u FASTA formatu. Svako očitavanje predstavlja fragment genoma te sadrži unaprijed umetnute supstitucije, umetanja i brisanja. Time je moguće rezultate detekcije varijanti usporediti s poznatim skupom točnih rješenja i procijeniti uspješnost implementacije.

Za skup podataka *lambda* korišteno je 247 simuliranih očitavanja prosječne duljine 8131.73 nukleotida. Od ukupnog broja očitavanja, u daljnjoj obradi korištena su 232 poravnanja, što čini 93.93% svih očitavanja.

Za skup podataka *E. coli* korišteno je 31415 simuliranih očitavanja prosječne duljine 7967.95 nukleotida. Od ukupnog broja očitavanja, u daljnjoj obradi korišteno je 29567 poravnanja, što čini 94.12% svih očitavanja.

Za evaluaciju rezultata korišteni su skupovi točnih varijanti koji sadrže položaj i tip svake umetnute mutacije. Ti su podaci korišteni za izračun metrika uspješnosti poput točnosti, preciznosti, odziva i mjere F1.

4 Implementacija

Implementacija je provedena u programskom jeziku C++ uz korištenje standardnih biblioteka jezika C++.

Prije pozivanja varijanti simulirana očitavanja mapirana su na referentni genom pomoću alata *Minimap2*. Dobiveni SAM zapis pretvoren je u BAM format, sortiran te obrađen alatima iz paketa *Samtools*. Iz sortiranog BAM zapisa generiran je *mpileup* zapis pomoću naredbe `samtools mpileup`. Taj zapis zatim je obrađen vlastitim *mpileup* parserom, čime je dobiveno zasebno rješenje koje se koristilo za usporedbu s rezultatima vlastitog algoritma za pozivanje varijanti.

Cijeli postupak pokretanja vanjskih alata automatiziran je skriptom `run.sh`. Najprije se očitavanja

poravnavaju na referentni genom naredbom:

```
- minimap2 -x map-ont -a --eqx
data/ecoli.fasta
- data/ecoli_simulated_reads.fasta >
data/aln.sam
```

Opcija `-x map-ont` koristi postavke prilagođene dugim očitanjima nalik Oxford Nanopore očitanjima. Opcija `-a` određuje da se rezultat spremi u SAM formatu, dok opcija `-eqx` omogućuje da se u CIGAR zapisu eksplicitno razlikuju podudaranja i nepodudaranja baza. Na taj se način dobiva tekstualna SAM datoteka koja sadrži podatke o poravnanju svakog očitavanja na referentni genom.

Nakon toga SAM datoteka pretvara se u BAM format:

```
- samtools view -Sb data/aln.sam >
data/aln.bam
```

BAM je binarni oblik SAM zapisa te je kompaktiji i prikladniji za daljnju obradu. Dobiveni BAM zatim se sortira prema koordinatama na referentnom genomu:

```
- samtools sort data/aln.bam -o
data/aln.sorted.bam
```

Sortiranje je potrebno kako bi se poravnanja uređila po pozicijama na referentnom genomu, što omogućuje ispravnu i učinkovitiju izradu pileup zapisa. Iz sortiranog BAM-a generira se `pileup.txt`:

```
- samtools mpileup -f data/ecoli.fasta
data/aln.sorted.bam > pileup.txt
```

Naredba `samtools mpileup` za svaku poziciju referentnog genoma zapisuje referentnu bazu, broj očitavanja koja pokrivaju tu poziciju te baze opažene u poravnanim očitanjima. Tako dobiveni zapis koristi se kao ulaz u vlastiti parser i vlastiti algoritam za detekciju varijanti. Vrijeme izvođenja ove naredbe za skup podataka *lambda* iznosilo je 0.1 s, dok je za veći skup podataka *E. coli* iznosilo 165.5 s.

4.1 Algoritam za detekciju

Algoritam za detekciju varijanti temelji se na obradi SAM zapisa dobivenog poravnanjem očitavanja na referentni genom. Zapis se čita redak po redak, pri čemu se preskaču nemapirana očitavanja te

sekundarna i dodatna poravnanja. Za svako očitavanje dohvaćaju se početna pozicija poravnanja, CIGAR zapis i sekvenca. Ako je očitavanje mapirano na negativni lanac, sekvenca se prije analize pretvara u reverzni komplement.

Svako očitavanje obrađuje se pomoću CIGAR zapisa. Najprije se računa pokrivenost referentnih pozicija, a zatim se prikupljaju dokazi za moguće varijante. Nepodudaranja označena operacijom X zapisuju se kao supstitucije, umetanja označena operacijom I pridružuju se prethodnoj referentnoj poziciji, dok se brisanja označena operacijom D zapisuju na pozicijama koje su preskočene u očitavanju. Operacije koje ne odgovaraju izravno referentnim pozicijama, poput umetanja i neporavnatih dijelova očitavanja, ne povećavaju pokrivenost.

Za svaku potencijalnu varijantu bilježi se broj očitavanja koja je podržavaju. Nakon obrade svih očitavanja varijante se grupiraju prema poziciji i tipu promjene, određuje se najčešće podržana alternativna baza te se računa učestalost varijante kao omjer potpore i ukupne pokrivenosti te pozicije. Varijanta se prihvaća samo ako zadovoljava zadani prag minimalne potpore i minimalne učestalosti. Konačni rezultat je skup detektiranih supstitucija, umetanja i brisanja zapisanih u CSV datoteku.

4.2 *Lambda* genom


Skup podataka *lambda* korišten je za razvoj početne implementacije algoritma za pozivanje varijanti. Budući da je genom kraći, varijante su detektirane izravnom obradom SAM zapisa nastalog poravnanjem očitavanja na referentni genom.

Na ovom skupu podataka korišten je prag potpore od najmanje 2 očitavanja te minimalna učestalost varijante od 70% očitavanja na promatranoj poziciji. Time se zadržava osjetljivost algoritma na manjem genomu, uz istovremeno uklanjanje varijanti koje su podržane samo pojedinačnim očitanjima.

Konačni skup detektiranih varijanti zapisuje se u CSV datoteku te uspoređuje s poznatim skupom točnih varijanti i s rješenjem dobivenim obradom *mpileup* zapisa.

4.3 *E. coli* genom

Nakon validacije pristupa na skupu podataka *lambda*, implementacija je proširena na skup podataka




Slika 1: Podjela pokrivenosti poravnanja na skupu *lambda*.

E. coli, koji sadrži znatno veći genom i veći broj očitavanja. Zbog veličine skupa podataka i većeg broja mogućih pogrešaka pri očitavanju, korišteni su stroži kriteriji filtriranja.

Za prihvaćanje varijante zahtijeva se minimalna pokrivenost od 3 očitavanja te odgovarajuća potpora promatranoj promjeni. Konačni skup detektiranih varijanti zapisuje se u CSV datoteku.

Za isti skup podataka dodatno je generiran i *mpileup* zapis pomoću alata *Samtools*. Taj zapis obrađen je vlastitim parserom kako bi se dobilo zasebno rješenje. Rezultati vlastitog algoritma zatim se uspoređuju s poznatim skupom točnih varijanti i s rješenjem dobivenim iz *mpileup* zapisa.



Slika 2: Podjela pokrivenosti poravnanja na skupu *E. coli*.

5 Rezultati

Rezultati su analizirani zasebno za skupove podataka *lambda* i *E. coli*. Za svaki skup mjereno je vrijeme izvođenja dijela programa za pozivanje varijanti, a dobiveni rezultati uspoređeni su s rješenjem dobivenim parsiranjem *mpileup* zapisa te s

poznatim skupom točnih varijanti.

5.1 *Lambda*

Za skup podataka *lambda* vrijeme izvođenja algoritma za pozivanje varijanti iznosilo je 0.47 s.

Usporedba s rješenjem dobivenim parsiranjem *mpileup* zapisa:

- TP: 130
- FP: 95
- FN: 34
- Točnost: 50.19%
- Preciznost: 57.78%
- Odziv: 79.27%
- F1: 66.84%

Usporedba s poznatim skupom točnih varijanti:


- TP: 154
- FP: 71
- FN: 49
- Točnost: 56.20%
- Preciznost: 68.44%
- Odziv: 75.86%
- F1: 71.96%

Napomena: navedeni rezultati za poznati skup varijanti dobiveni su uz pomak pozicija insercija za -1 , jer se poznati skup točnih varijanti i zapis dobiven iz *mpileup* formata razlikuju u načinu pozicioniranja insercija.

5.2 *E. coli*

Za skup podataka *E. coli* vrijeme izvođenja algoritma za pozivanje varijanti iznosilo je 118.65 s. Dulje vrijeme izvođenja posljedica je znatno većeg genoma i većeg broja očitavanja u odnosu na skup podataka *lambda*.

Usporedba s rješenjem dobivenim parsiranjem *mpileup* zapisa:




Slika 3: Odziv za skup podataka *lambda* po broju očitavanja.

- TP: 14511
- FP: 3653
- FN: 3
- Točnost: 79.88%
- Preciznost: 79.89%
- Odziv: 99.98%
- F1: 88.81%

Usporedba s poznatim skupom točnih varijanti:

- TP: 17058
- FP: 1101
- FN: 2436
- Točnost: 82.83%
- Preciznost: 93.94%
- Odziv: 87.50%
- F1: 90.61%

Napomena: navedeni rezultati za poznati skup varijanti dobiveni su uz pomak pozicija insercija za -1 , jer se poznati skup točnih varijanti i zapis dobiven iz *mpileup* formata razlikuju u načinu pozicioniranja insercija.



Slika 4: Detektirane mutacije na skupu podataka *E. coli* po tipu mutacije, prema poznatom skupu točnih varijanti.

6 Zaključak

U projektu je razvijen jednostavan pipeline za detekciju varijanti iz simuliranih očitavanja treće generacije sekvenciranja. Implementacija uspješno prepoznaje supstitucije, umetanja i brisanja te pokazuje kako se kombinacijom postojećih bioinformatičkih alata i vlastite C++ obrade mogu dobiti korisni rezultati za manje i veće genome.

Literatura

1. Li, H. *Minimap2: pairwise alignment for nucleotide sequences*. Bioinformatics, 2018.
2. *Minimap2 Documentation*. Dostupno na: <https://github.com/lh3/minimap2>
3. Danecek, P. i sur. *Twelve years of SAMtools and BCFtools*. Gigascience, 2021.
4. Li, H. i sur. *The Sequence Alignment/Map format and SAMtools*. Bioinformatics, 2009.
5. Jain, M., Olsen, H. E., Paten, B., Akeson, M. *The Oxford Nanopore MinION: delivery of nanopore sequencing to the genomics community*. , 2016.
6. Logsdon, G. A., Vollger, M. R., Eichler, E. E. *Long-read human genome sequencing and its applications*. 2020.

7. Domazet-Lošo, M., Šikić, M. *Skripta iz kolegija Bioinformatika*. Fakultet elektrotehnike i računarstva, Sveučilište u Zagrebu.

8. PacBio Documentation. Dostupno na: <https://www.pacb.com>