

Pronalazak mutacija pomoću treće generacije sekvenciranja

Monika Hušnjak, Marko Kosmač

31. svibnja 2026.

Sažetak

U radu je opisana implementacija postupka za pronalazak mutacija pomoću podataka treće generacije sekvenciranja. Korišteni su skupovi podataka za genome *lambda* i *Escherichia coli*, uz simulirana očitavanja koja sadrže poznate supstitucije, umetanja i brisanja. Očitavanja su mapirana na referentni genom alatom *Minimap2*, a dobiveni zapisi obrađeni su alatima *Samtools* i vlastitim programima u jeziku C++. Razvijeni algoritam detektira varijante iz poravnanja i filtrira ih prema pokrivenosti i potpori očitavanja. Dobiveni rezultati uspoređuju se s poznatim skupom točnih varijanti te s dodatnim rješenjem dobivenim parsiranjem *mpileup* zapisa.

1 Uvod

Sekvenciranje DNA jedna je od najvažnijih metoda moderne bioinformatike jer omogućuje određivanje redoslijeda nukleotidnih baza u genomu te analizu genetskih promjena. Razvojem tehnologija sekvenciranja pojavile su se metode treće generacije koje omogućuju dobivanje vrlo dugih očitavanja DNA. Duga očitavanja olakšavaju analizu kompleksnih i repetitivnih dijelova genoma, ali istovremeno imaju veću stopu pogreške u odnosu na tehnologije druge generacije.

Za obradu podataka dobivenih sekvenciranjem treće generacije koriste se specijalizirani algoritmi i alati za poravnanje sekvenci. Jedan od najčešće korištenih alata je *minimap2*, koji omogućuje brzo i učinkovito mapiranje dugih očitavanja na referentni genom. Nakon mapiranja moguće je analizirati dobivena poravnanja i pronaći razlike između referentnog i mutiranog genoma.

Cilj ovog projekta je identificirati mutacije u odnosu na referentni genom korištenjem očitavanja dobivenih sekvenciranjem treće generacije. Proma-

trane mutacije uključuju supstitucije, umetanje i brisanje baza. Ulazni podaci zadani su u FASTA formatu, dok se rezultati analize zapisuju u CSV datoteku koja sadrži tip mutacije, njezinu poziciju i baze koje se pojavljuju u mutaciji.

Implementacija se uspoređuje s rezultatima *SAMtools-a*, standardnog skupa alata za obradu i analizu podataka sekvenciranja zapisanih u SAM/BAM formatima. *SAMtools* omogućuje sortiranje, indeksiranje i pregled poravnanja te generiranje podataka potrebnih za detekciju varijanti.

2 Generacije sekvenciranja

Sekvenciranje DNA razvilo se kroz tri generacije koje se razlikuju po načinu rada, brzini i duljini očitavanja

2.1 Prva generacija

Temelji se na *Sangerovoj* metodi koja koristi dideoksinukleotide za prekidanje sinteze DNA u različitim duljinama. Nastali fragmenti razdvajaju se elektroforezom, čime se određuje slijed baza. Ova metoda je vrlo točna, ali spora i skupa, pa se koristi za analizu manjih regija DNA i za potvrdu već pronađenih mutacija.

2.2 Druga generacija

Uključuje tehnologije poput *Illumina* i *Ion Torrent* sustava. *Illumina* koristi fluorescentno označene nukleotide koji se očitavaju tijekom sinteze DNA, dok *Ion Torrent* detektira promjene *pH* vrijednosti pri ugradnji nukleotida. Ova generacija omogućuje paralelno sekvenciranje milijuna fragmenata DNA, što ju čini učinkovitom za analizu cijelih genoma i detekciju čestih mutacija poput točkastih mutacija, umetanja i brisanja.

2.3 Treća generacija

Obuhvaća *PacBio SMRT* i *Oxford Nanopore*, tehnologije koje omogućuju čitanje pojedinačnih molekula DNA u stvarnom vremenu. *PacBio* prati fluorescenciju tijekom sinteze, dok *Nanopore* mjeri promjene električne struje dok DNA prolazi kroz nanopore. Njihova najveća prednost su duga očitavanja, što može otkriti složene strukturne varijacije, ponavljajuće regije i kompleksne mutacije koje su teško uočljive metodama za kraća očitavanja.

Sve tri generacije imaju važnu primjenu u genetici i medicini, ali treća generacija je posebno korisna za analizu kompleksnih genoma i preciznije razumijevanje velikih strukturnih promjena u DNA.

3 Skup podataka

Za testiranje implementacije korišteni su skupovi podataka za *Escherichia coli* i *lambda*. Referentni genomi pohranjeni su u FASTA formatu koji se sastoji od zaglavlja sekvence i niza nukleotida zapisanih bazama A, C, G i T. Genom *E. coli* veličine je približno 4,6 milijuna baznih parova, dok genom *lambda* sadrži oko 48,5 tisuća baznih parova.

Uz referentne genome korištena su simulirana očitavanja također zapisana u FASTA formatu. Svako očitavanje predstavlja fragment genoma te sadrži unaprijed umetnute supstitucije, umetanja i brisanja. Time je moguće rezultate detekcije varijanti usporediti s poznatim skupom točnih rješenja i procijeniti uspješnost implementacije.

Za evaluaciju rezultata korišteni su skupovi točnih varijanti koji sadrže položaj i tip svake umetnute mutacije. Ti su podaci korišteni za izračun metrika uspješnosti poput točnosti, preciznosti, odziva i mjere F1.

4 Implementacija

Implementacija je provedena u programskom jeziku C++ uz korištenje standardnih biblioteka jezika C++.

Prije pozivanja varijanti simulirana očitavanja mapirana su na referentni genom pomoću alata *Minimap2*. Dobiveni SAM zapis pretvoren je u BAM format, sortiran te obrađen alatima iz paketa *Samtools*. Iz sortiranog BAM zapisa generiran je *mpileup*

leup zapis pomoću naredbe `samtools mpileup`. Taj zapis zatim je obrađen vlastitim *mpileup* parserom, čime je dobiveno zasebno rješenje koje se koristilo za usporedbu s rezultatima vlastitog algoritma za pozivanje varijanti.

4.1 Lambda

Skup podataka *lambda* korišten je za razvoj početne implementacije algoritma za pozivanje varijanti. Budući da je genom kraći, varijante su detektirane izravnom obradom SAM zapisa nastalog poravnanjem očitavanja na referentni genom.

Program prolazi kroz poravnata očitavanja i analizira njihov CIGAR zapis. Pritom se očitavanja mapirana na negativni lanac obrađuju pomoću reverznog komplementa kako bi se sve varijante prikazale u referentnom smjeru genoma. Na temelju CIGAR operacija prepoznaju se supstitucije, umetanja i brisanja.

Za svaku potencijalnu varijantu računa se broj očitavanja koja je podržavaju te ukupna pokrivenost na toj poziciji. Varijanta se prihvata ako ima potporu od najmanje 2 očitavanja i ako čini najmanje 70 posto očitavanja na toj poziciji. Time se smanjuje utjecaj pojedinačnih pogrešaka sekvenciranja i sprječava prijavljivanje nepouzdatih varijanti.

Konačni skup detektiranih varijanti zapisuje se u CSV datoteku te uspoređuje s poznatim skupom točnih varijanti i s rješenjem dobivenim obradom *mpileup* zapisa.

4.2 E. coli

Nakon validacije pristupa na skupu podataka *lambda*, implementacija je proširena na skup podataka *E. coli*, koji sadrži znatno veći genom i veći broj očitavanja. Zbog veličine skupa podataka i većeg broja mogućih pogrešaka pri očitavanju, korišteni su stroži kriteriji filtriranja.

Vlastiti algoritam za pozivanje varijanti primjenjuje filtriranje prema pokrivenosti i potpori promatrane promjene. Za prihvatanje varijante zahtijeva se minimalna pokrivenost od 3 očitavanja te odgovarajuća potpora promatranoj promjeni. Konačni skup detektiranih varijanti zapisuje se u CSV datoteku.

Za isti skup podataka dodatno je generiran i *mpileup* zapis pomoću alata *Samtools*. Taj zapis obrađen je vlastitim parserom kako bi se dobilo zasebno

rješenje. Rezultati vlastitog algoritma zatim se uspoređuju s poznatim skupom točnih varijanti i s rješenjem dobivenim iz *mpileup* zapisa.

5 Rezultati

Rezultati su analizirani zasebno za skupove podataka *lambda* i *E. coli*. Za svaki skup mjereno je vrijeme izvođenja dijela programa za pozivanje varijanti, a dobiveni rezultati uspoređeni su s rješenjem dobivenim parsiranjem *mpileup* zapisa te s poznatim skupom točnih varijanti.

5.1 *Lambda*


Za skup podataka *lambda* vrijeme izvođenja algoritma za pozivanje varijanti iznosilo je 0.47 s.

Usporedba s rješenjem dobivenim parsiranjem *mpileup* zapisa:

- TP: 121
- FP: 104
- FN: 43
- Točnost: 45.15%
- Preciznost: 53.78%
- Odziv: 73.78%
- F1: 62.21%

Usporedba s poznatim skupom točnih varijanti:

- TP: 154
- FP: 71
- FN: 49
- Točnost: 56.20%
- Preciznost: 68.44%
- Odziv: 75.86%
- F1: 71.96%



Slika 1: Odziv za skup podataka *lambda* po broju očitavanja.

5.2 *E. coli*


Za skup podataka *E. coli* vrijeme izvođenja algoritma za pozivanje varijanti iznosilo je 118.65 s. Dulje vrijeme izvođenja posljedica je znatno većeg genoma i većeg broja očitavanja u odnosu na skup podataka *lambda*.

Usporedba s rješenjem dobivenim parsiranjem *mpileup* zapisa:

- TP: 13755
- FP: 4404
- FN: 759
- Točnost: 72.71%
- Preciznost: 75.75%
- Odziv: 94.77%
- F1: 84.20%

Usporedba s poznatim skupom točnih varijanti:

- TP: 17058
- FP: 1101
- FN: 2436
- Točnost: 82.83%
- Preciznost: 93.94%
- Odziv: 87.50%
- F1: 90.61%



Slika 2: Odziv za skup podataka *E. coli* po broju očitavanja.

8. PacBio Documentation. Dostupno na: <https://www.pacb.com>

6 Zaključak

U projektu je razvijen jednostavan pipeline za detekciju varijanti iz simuliranih očitavanja treće generacije sekvenciranja. Implementacija uspješno prepoznaje supstitucije, umetanja i brisanja te pokazuje kako se kombinacijom postojećih bioinformatičkih alata i vlastite C++ obrade mogu dobiti korisni rezultati za manje i veće genome.

Literatura

1. Li, H. *Minimap2: pairwise alignment for nucleotide sequences*. Bioinformatics, 2018.
2. *Minimap2 Documentation*. Dostupno na: <https://github.com/lh3/minimap2>
3. Danecek, P. i sur. *Twelve years of SAMtools and BCFtools*. Gigascience, 2021.
4. Li, H. i sur. *The Sequence Alignment/Map format and SAMtools*. Bioinformatics, 2009.
5. Jain, M., Olsen, H. E., Paten, B., Akeson, M. *The Oxford Nanopore MinION: delivery of nanopore sequencing to the genomics community*, 2016.
6. Logsdon, G. A., Vollger, M. R., Eichler, E. E. *Long-read human genome sequencing and its applications*. 2020.
7. Domazet-Lošo, M., Šikić, M. *Skripta iz kolegija Bioinformatika*. Fakultet elektrotehnike i računarstva, Sveučilište u Zagrebu.